SAE 301

Base de données de films

Groupe : Margaret (groupe A - ***CineTrackers***)

- Riad ABAR
- Souheila FRIH
- Abasse KADERBHAI POTHIWALA
- Mouhamed Fadel THIAM

Rapport personnel : Tâches effectuées sur la période du 26 octobre au 8 novembre.

Rapport de : Riad ABAR

Tâche n°1 : Identifier les informations et les liens entre les données

Pour notre projet de cinéma (SAÉ), nous devons organiser toutes les données du site IMDb pour qu'elles soient faciles à utiliser dans notre application. Ce premier rapport explique comment nous avons classé ces informations et comment elles sont reliées entre elles.

1. Organisation des données

Pour éviter de répéter les mêmes informations partout et garder une base de données propre, nous l'avons découpée en plusieures tables:

A. Les tables principales

- **PERSONNES** : Contient toutes les infos sur les acteurs, réalisateurs et techniciens (nom, prénom, dates de naissance et de mort).
- **OEUVRE** : Regroupe tous les films, séries et épisodes. Chaque œuvre a un titre, une date de sortie, une durée, etc.
- **EPISODE** : Sert à lier les épisodes aux séries télévisées pour savoir à quelle saison et quel épisode ils appartiennent.

B. Les classements et catégories

- **TYPE_OEUVRE** : Dit si c'est un film, une série ou un court-métrage.
- **GENRE** et **OEUVRE_GENRE** : Permettent de dire de quel genre est un film (action, comédie, drame). Comme un film peut avoir plusieurs genres, on utilise un petit tableau de lien au milieu.
- **PROFESSION_CATEGORIES** et **JOB** : Précisent ce que fait exactement une personne sur un film (acteur, réalisateur, monteur, etc.).

C. Les détails et notes

- **REGION** et **LANGUE** : Aident à gérer les titres de films traduits selon les pays.
- **ADAPTATION_INTERNATIONAL** : Associe un film à son titre dans une autre langue ou un autre pays.
- **EVALUATION** : Stocke la note moyenne et le nombre de votes pour chaque film, séparément pour que ce soit plus simple à mettre à jour.

2. Pourquoi avons-nous fait ces choix ?

1. **Pas de doublons** : En séparant bien chaque élément (les personnes d'un côté, les films de l'autre), on évite de réécrire les mêmes choses 10 fois.
2. **Recherches rapides** : On a ajouté des repères (les index) sur les éléments qu'on cherche le plus souvent pour que le site web réponde plus vite.
3. **Découpage propre** : Les gros morceaux de texte avec des virgules (comme la liste des genres d'un film) sont séparés pour entrer proprement dans notre base de données.

Tâche n°2 : Les scripts pour récupérer et insérer les données

Nous avons écrit les scripts pour prendre les gros fichiers fournis par IMDb et les ranger dans notre base de données.

1. Fonctionnement du script

Le travail se fait en deux étapes :

1. **La création (creation_tables.sql)** : On fabrique les cases et les tableaux vides avec les bonnes règles.
2. **Le remplissage (importations_donnees.sql)** : On prend les fichiers d'origine et on copie les données dedans en les transformant pour qu'elles rentrent bien.

2. Nos choix dans ces scripts

A. Gérer les listes séparées par des virgules

Dans les fichiers d'IMDb, des choses comme les genres ou les métiers sont collés dans une seule phrase avec des virgules.

- On utilise des fonctions pour couper ces phrases et créer une ligne par élément.
- Ça permet de ranger chaque genre ou chaque métier dans sa propre case bien propre.

B. Ordre de remplissage des tables

On ne peut pas mettre des données n'importe comment :

1. On remplit d'abord les tableaux de base qui ne dépendent de personne (PERSONNES, GENRE, LANGUE, etc.).
2. Ensuite, on remplit les tableaux comme OEUVRE ou EPISODE en allant chercher les identifiants créés juste avant.

C. Gérer les rôles des équipes (PARTICIPATION_OEUVRE)

- On rassemble les acteurs, les réalisateurs et les scénaristes dans un même grand tableau de participation.
- On utilise une sécurité pour vérifier qu'on n'ajoute pas deux fois la même personne sur le même film pour le même rôle, ce qui évite les doublons inutiles.

3. Import beaucoup trop lourd

En testant nos scripts, nous faisons face à un problème majeur : l'importation complète des données prend énormément de temps (environ plus de trois heures).

Plusieurs raisons expliquent cela :

- Le volume de données de départ d'IMDb est gigantesque (10Go de données).
- Nos scripts font beaucoup de transformations et de vérifications en même temps.
- Comme nous ne sommes pas du tout au bout du projet, notre code n'est pas encore totalement optimisé.

Pour la suite, nous devons absolument trouver des solutions pour accélérer tout ça. Nous pensons par exemple à :

- Importer uniquement une portion des données (un échantillon) pour travailler plus vite au quotidien.
- Améliorer nos requêtes SQL pour qu'elles soient plus directes.
- Mettre en place des index au bon moment ou vider les tables temporaires plus efficacement.